

개선된 YOLO11 기반 연기 및 화재 탐지 모델

A Smoke and Fire Detection Model Based on Improved YOLO11

Penglei Wang · Xin Fan* · Zhezhe Zhu · Shengwei Tian · Long Yu

신장대학교 소프트웨어대학, 우루무치, 신장, 중국

초록

연기 및 화재 탐지는 환경 모니터링과 재난 예방에서 핵심적인 역할을 한다. 그러나 연기와 화재가 매우 다양하고 복잡한 형태로 나타나기 때문에, 기존의 딥러닝 기반 탐지 방법은 특징 추출 능력이 부족하고 오탐률이 높은 경우가 많다. 이러한 문제를 해결하기 위해 본 논문에서는 개선된 YOLO11n을 기반으로 하는 새로운 연기 및 화재 탐지 방법인 RSW-YOLO를 제안한다. 첫째, C3k2 모듈에 구조적 재매개변수화 기술을 도입한 RepC3k2를 적용하여 효율적인 추론을 유지하면서 모델의 특징 추출 능력과 탐지 정확도를 높인다. 둘째, SEGE 어텐션을 사용해 관련 없는 배경 정보를 억제하고 핵심 특징 표현을 강화함으로써 가짜 표적의 간섭을 효과적으로 줄인다. 마지막으로 WIoUv3 손실 함수를 적용하여 데이터셋 내 저품질 인스턴스가 유발하는 불리한 그라디언트의 영향을 낮춘다. D-Fire 데이터셋 평가에서 RSW-YOLO는 정밀도(P) 80.8%, 재현율(R) 73.1%, mAP@50 79.8%를 달성하여 기존 방법보다 유의미하게 우수한 성능을 보였다. 본 연구는 복잡한 환경에서의 연기 및 화재 탐지를 위한 새로운 기술적 패러다임을 제공한다.

핵심어: 연기 및 화재 탐지; YOLO11n; RepVGG; WIoUv3

I. 서론

연기 및 화재 탐지 시스템은 현대 보안 감시에서 매우 중요하며, 건물·산업 시설·공공장소에서 핵심적인 역할을 한다. 전통적인 탐지 방식은 화재 초기 단계에서 경보를 울리기 위해 연기 센서와 열 센서에 의존한다. 인공지능의 발전에 따라 이 분야는 지능형 시스템으로 전환되고 있다. 딥러닝과 컴퓨터 비전 기술을 통해 연기와 화재를 더 빠르고 정확하게 인식할 수 있게 되었고, 시스템 성능도 효과적으로 향상되었다.

최근 이 분야의 연구는 상당한 진전을 이루었다. Safarov 등[1]은 ViT 구조를 YOLOv5s에 통합하여 까다로운 환경 조건에서 연기와 화재를 탐지하는 향상된 모델을 개발했다. Zhao 등[2]은 3차원 관점에서 특징 추출을 강화하여 소규모 화재 표적 탐지 성능을 크게 개선한 Fire-YOLO를 제안했다. Wang 등[3]은 ASPP와 CBAM을 결합한 YOLOv5s-ACE 모델을 설계하여 산불 탐지 정확도를 효과적으로 향상했다. Cao 등[4]은 특징 융합과 채널 어텐션 기술을 활용해 핵심 특징과 채널 정보를 결합함으로써 효율적이고 정확한 화재 인식을 구현했다.

AI 기반 연기 및 화재 탐지는 크게 발전했지만, 고품질 이미지의 부족, 경계 상자 주석의 어려움, 화재 상황의 복잡성과 가변성 때문에 효과적인 특징 추출이 여전히 어렵고 오탐률도 비교적 높다[5]. 이에 본 연구는 YOLO11n[6]을 기반으로 하는 새로운 연기 및 화재 탐지 모델 RSW-YOLO를 제안한다. 제안 방법은 탐지 정확도를 높이는 동시에 계산 자원을 최적화하여 효율적인 화재 예방 및 조기 경보 능력을 실현한다.

본 연구의 주요 기여는 다음과 같다. (1) RepVGG 블록을 포함하는 RepC3k2 모듈을 도입해 기존 네트워크의 표준 C3k2 모듈을 대체했다. 이를 통해 효율적인 추론을 유지하면서 모델의 특징 추출 능력과 탐지 성능을 크게 높였다. (2) 백본에 SEGE 어텐션을 통합하여 특징 채널의 중요도를 적응적으로 보정했다. 관련 없는 정보를 억제하고 핵심 특징 표현을 강화함으로써 가짜 표적의 간섭을 크게 줄였다. (3) 기존 Ciou 손실 함수를 WIoUv3로 대체하여 객체 탐지 학습 데이터에서 극단적 샘플에 모델이 지나치게 집중하는 현상을 완화하고, 전반적인 모델 성능을 크게 향상했다.

II. 제안 방법

초기 연기와 화재를 빠르고 정확하게 탐지하기 위해 RSW-YOLO 모델을 개발했다(그림 1). 이 모델은 개선된 RepC3k2 모듈을 통해 특징 추출을 강화하고, 백본 네트워크에 SEGE 어텐션 메커니즘을 통합해 배경 간섭을 효과적으로 억제하며, WIoUv3를 사용해 품질이 서로 다른 앵커 박스의 학습 가중치를 균형 있게 조절함으로써 탐지 성능을 크게 향상한다.

A. RepC3k2

C3k2 모듈은 YOLO11의 핵심 특징 추출 계층이며, 그 성능은 네트워크의 장면 적응성과 탐지 정확도에 결정적인 영향을 미친다. 본 연구는 원래 C3k2 모듈의 DarknetBottleneck을 RepVGG Bottleneck으로 대체한 개선 모듈 RepC3k2를 제안한다(그림 2). 이 변경은 학습 단계에서 RepVGG의 다중 분기 장점을 충분히 활용하여[7] 모델의 표현 학습 능력을 높이는 동시에 추론 효율을 유지한다.

그림 2. RepC3k2 및 Bottleneck 모듈 구성도(원문 참조)

구체적으로 RepC3k2 모듈은 학습 과정에서 다중 분기 토폴로지를 통해 특징 표현 능력을 강화하고 더 풍부한 특징 정보를 포착한다. 추론 과정에서는 구조적 재매개변수화 기술을 이용해 다중 분기 구조를 간결한 단일 경로 설계로 통합함으로써 계산 복잡도와 파라미터 규모를 크게 줄인다. 이처럼 학습과 추론을 분리한 설계는 추론 속도를 높이고 복잡한 배경에서 모델의 특징 전달 및 추출 능력을 효과적으로 강화하여 객체 탐지의 전반적인 성능을 크게 향상한다.

B. 가우시안 향상을 결합한 Squeeze-and-Excitation 모델

백본 네트워크에서 모듈이 중첩되면서 발생하는 특징 앨리어싱 효과를 줄이기 위해 SEGE(Squeeze-and-Excitation with Gaussian Enhancement) 어텐션 모듈을 제안한다. 이 모듈은 특징 채널의 중요도를 적응적으로 재조정하고, 관련 없는 배경 정보를 억제하며, 핵심 특징 표현을 강화한다.

그림 3. SEGE 모듈 개략도(원문 참조)

그림 3과 같이 크기가 $H \times W \times C$ 인 입력 샘플 이미지 X 에 대해, squeeze 단계는 전역 평균 풀링을 통해 이미지를 $1 \times 1 \times C$ 채널 기술자로 압축하여 전역 특징 분포를 포착한다. Squeeze 연산은 다음과 같이 표현된다.

$$S_{1 \times 1 \times C} = (1 / H \times W) \sum_{i=1..H} \sum_{j=1..W} F_c(i, j) \quad (1)$$

이후 excitation 단계는 ReLU와 Sigmoid 활성화 함수를 포함하는 연속된 두 개의 점별(1×1) 합성곱으로 구성되며, 채널 간 의존성을 종합적으로 포착해 각 입력 특징 맵의 채널 가중치를 생성한다. 연산식은 다음과 같다.

$$E_{1 \times 1 \times C} = \sigma(\text{Conv}_{1 \times 1 \times C}(\delta(\text{Conv}_{1 \times 1 \times C/r}(S_{1 \times 1 \times C})))) \quad (2)$$

여기서 σ 와 δ 는 각각 Sigmoid와 ReLU6 활성화 함수를 뜻한다. Conv는 출력 채널 수를 조정하는 1×1 합성곱 계층이다. C/r 은 채널 압축 비율을 제어하는 스케일 계수이며, C 는 출력 채널 수이고 r 은 하이퍼파라미터이다.

그다음 $1 \times 1 \times C$ 가중치 벡터는 채널별 곱셈을 통해 원래 특징 맵을 스케일링하여 적응적 특징 재가중을 수행한다. 이 과정은 관련 없는 특징을 억제하는 동시에 핵심 채널 정보에 대한 네트워크의 민감도를 높여 특징 표현을 개선한다.

$$X_{se} = X \odot E_{1 \times 1 \times C} \quad (3)$$

여기서 $\odot$ 는 원소별 곱셈을 뜻한다. SE 연산을 바탕으로 깊이별 분리 합성곱 계층과 가우시안 블러 계층 사이에 잔차 연결을 추가하여 네트워크의 특징 추출 및 표현 능력을 강화한다. 이 연결은 다중 수준 특징의 통합과 직접적인 그라디언트 흐름을 지원하여 그라디언트 소실과 모델 열화 문제를 효과적으로 완화하고 네트워크의 표현력과 전체 성능을 높인다.

구체적으로 5×5 깊이별 분리 합성곱은 채널 독립성을 유지하면서 국소 공간 패턴을 포착한다. 이어지는 가우시안 블러 합성곱은 공간 평활화를 수행하여 저주파 정보를 보존하면서 고주파 잡음을 효과적으로 약화하고, 계산 효율을 유지하면서 특징 강건성을 향상한다.

$$X_{gbc} = \text{GBConv}(\text{ReLU}(\text{BN}(\text{DWConv}(X)))) \quad (4)$$

여기서 DWConv는 깊이별 분리 합성곱, BN은 배치 정규화, GBConv는 가우시안 블러 합성곱을 뜻한다. 마지막으로 SE 모듈의 가중 표현과 가우시안 필터링 특징 맵을 원소별 덧셈으로 결합한 후 SiLU 활성화 함수를 이용해 비선형 변환한다.

$$X_{out} = \text{SiLU}(X_{se} + X_{gbc}) \quad (5)$$

본 연구는 채널 가중치를 적응적으로 학습하도록 백본 네트워크의 각 C3k2 구조 뒤에 SEGE 모듈을 통합했다. 이를 통해 배경 간섭을 효과적으로 억제하고 특징 판별 능력을 높여 오탐률을 낮췄다.

C. WIoUv3 손실

YOLO11은 기본 손실 계산 방법으로 Ciou를 사용하지만, 샘플 기여도와 경계 상자 크기 민감도의 균형을 맞추는 데 한계가 있다. 이를 해결하기 위해 동적 비단조 포커싱 메커니즘과 이상치 평가를 통해 품질이 서로 다른 앵커 박스에 그래디언트 이득을 합리적으로 배분하는 WIoUv3 손실 함수[8]를 도입한다. 이 방식은 품질이 다른 샘플 간 경계 상자 회귀 불균형을 해소하여 탐지기 성능을 높인다.

$$L_{WIoUv3} = r \times \exp(((b_{gtx} - b_{cx})^2 + (b_{gty} - b_{cgy})^2) / (W_g^2 + H_g^2)) \times (1 - IoU) \quad (6)$$

$$r = \beta / (\delta \alpha^\beta \delta) \quad (7) \quad \beta = L_{IoU}^* / L_{IoU} \in [0, +\infty) \quad (8)$$

여기서 δ 와 α 는 모델 구조에 맞춰 조정할 수 있는 하이퍼파라미터이다. 또한 이상치 정도 β 를 도입하면 앵커 박스의 품질을 동적으로 평가하고 그에 대응하는 그래디언트 가중치를 배분할 수 있어, 정상 품질의 앵커에 더 잘 집중하고 모델 성능을 향상할 수 있다.

III. 실험

A. 실험 환경

객체 탐지를 위해 Ubuntu 22.04, 12세대 Intel® Xeon® Silver 4314 CPU(2.40 GHz), RAM 24 GB, NVIDIA A30 GPU, CUDA 12.0, PyTorch 2.0.1, Python 3.9.21, Ultralytics 8.3.9로 연구 환경을 구성했다. 학습은 해상도 640×640, 배치 크기 16으로 수행했다. 최적화에는 모멘텀 0.937, 가중치 감쇠 5e-4, 초기 학습률 0.01의 SGD를 사용했다.

B. 실험 데이터셋

Gaia 연구진이 개발한 D-Fire 데이터셋[9]은 연기와 화재 탐지를 위해 특별히 설계된 이미지 데이터셋이다. 총 21,527 장 이상의 이미지가 화재만 포함(1,164장), 연기만 포함(5,867장), 연기와 화재 모두 포함(4,658장), 화재와 연기 모두 없음(9,838장)의 네 범주로 구성된다. 본 연구에서는 D-Fire 데이터셋을 학습 15,069장(70%), 검증 4,305장(20%), 테스트 2,157장(10%)으로 분할했다.

C. 평가 지표

모델 성능은 P(정밀도), R(재현율), mAP@0.5(IoU 임계값 0.5에서의 평균 정밀도 평균), GFLOPs, 추론 시간으로 평가한다. P는 전체 탐지 결과 중 올바르게 식별한 객체의 비율이며, R은 실제 객체 중 모델이 성공적으로 식별한 객체의 비율이다.

$$P = TP / (TP + FP) \quad (9) \quad R = TP / (TP + FN) \quad (10)$$

TP(True Positive)는 성공적으로 탐지한 객체, FP(False Positive)는 잘못 탐지한 객체, FN(False Negative)은 모델이 탐지하지 못한 객체를 뜻한다. mAP는 모든 범주의 AP(평균 정밀도)를 산술 평균한 값이다. mAP 계산은 예측 경계 상자가 정답 상자와 일치하는지 판단하는 기준인 IoU 임계값에 따라 달라진다.

$$mAP = (1/n) \sum_{i=1..n} AP_i \quad (11)$$

여기서 AP_i 는 i 번째 클래스의 AP이고, n 은 평가 대상 클래스의 총수이다.

D. 절제 실험

표 I. D-Fire 데이터셋 절제 실험 결과

WIoUv3	RepC3k2	SEGE	P (%)	R (%)	mAP@0.5 (%)	GFLOPs
			78.4	70.7	78.9	6.3
			79.5	71.3	79.1	6.3
			79.8	72.4	79.3	6.3
			80.8	73.1	79.8	6.6

제안한 각 개선 요소의 기여도를 D-Fire 데이터셋에서 절제 실험으로 평가했으며, 결과는 표 I과 같다. 먼저 예측 경계 상자 회귀 손실로 WIoUv3를 적용하면 저품질 앵커 박스가 야기하는 그래디언트 간섭이 줄어 P, R, mAP@0.5가 각각 1.1%, 0.5%, 0.2% 향상된다. 다음으로 C3k2 모듈에 구조적 재매개변수화 기술을 적용하면 추론 단계의 효율성을 유지하면서 모델 표현 능력이 강화되어 P, R, mAP@0.5가 각각 0.3%, 1.1%, 0.2% 추가 향상된다. 마지막으로 백본에 SEGE 어텐션 모듈을 도입하면 채널 가중치를 적응적으로 조정해 관련 없는 정보와 가짜 표적의 간섭을 억제하며, P, R, mAP@0.5가 각각 1.0%, 0.7%, 0.5% 더 향상된다.

E. 비교 실험

표 II. D-Fire 데이터셋에서 다른 방법과의 비교

방법	P (%)	R (%)	mAP@50 (%)	시간 (ms)	GFLOPs
YOLOv5s	79.7	72.7	78.2	2.2	15.8
YOLOX tiny	76.8	69.8	75.7	2.7	15.4
YOLOv6n	77.8	69.8	77.6	1.3	11.3
YOLOv7 tiny	78.3	72.2	78.4	1.2	13.0
YOLOv8n	77.8	70.0	77.4	0.8	8.1
GELAN	78.4	69.5	77.9	1.0	8.1
YOLOv9	78.8	70.3	78.0	3.5	18.1
YOLOv10n	78.3	69.5	77.1	0.9	8.2
ESFD-YOLOv8n	80.1	72.7	79.4	1.0	10.8
YOLO11n	78.4	70.7	78.9	1.3	6.3
RSW-YOLO	80.8	73.1	79.8	1.5	6.6

제안한 RSW-YOLO 모델의 효과를 평가하기 위해 D-Fire 데이터셋에서 다양한 최신 연기 및 화재 탐지 방법과 성능을 비교했다. 비교에는 YOLO 계열 10종이 포함되었다. 최고값을 굵게 표시한 표 II의 종합 결과는 RSW-YOLO의 우수성을 명확히 보여준다. RSW-YOLO는 P 80.8%, R 73.1%, mAP@0.5 79.8%, 추론 시간 1.5ms, GFLOPs 6.6을 달성했다. 기준 모델 YOLO11n과 비교하면 추론 시간과 GFLOPs는 소폭 증가했지만 P와 R은 각각 2.4%, mAP@0.5는 0.9% 향상되었다. 평가된 모델 중 RSW-YOLO는 낮은 GFLOPs와 빠른 추론 시간을 유지하면서 P, R, mAP@0.5에서 모두 가장 높은 값을 기록했다. 특히 ESFD-YOLOv8n[10] 대비 GFLOPs를 61.1% 수준으로 줄이면서도 P, R, mAP@0.5를 각각 0.7%, 0.4%, 0.4% 개선하여 더 적은 계산 비용으로 우수한 정확도를 입증했다.

IV. 결론

연기 및 화재의 조기 예방과 신속한 대응을 실현하기 위해 RepC3k2, SEGE, WIoUv3 손실 등의 핵심 개선 요소를 통합한 YOLO11n 기반의 새로운 모델 RSW-YOLO를 제안했다. 실험 결과, RSW-YOLO는 계산 효율을 유지하면서 탐지 정확도를 크게 향상하고 D-Fire 데이터셋에서 최신 방법보다 우수한 성능을 보였다. 본 연구는 연기 및 화재 탐지 기술의 적용과 발전을 강력하게 뒷받침한다. 향후에는 더 크고 다양한 데이터셋으로 모델을 최적화하고 엣지 장치에 배포하여 연기 및 화재 탐지의 성능과 실용성을 높일 예정이다.

감사의 글

본 연구는 텐산 인재 양성 프로그램(No. 2023TSYCLJ0023)의 지원을 받아 수행되었다.

참고문헌

- [1] Safarov F, Muksimova S, Kamoliddin M, et al. 복잡한 환경에서의 화재 및 연기 탐지. *Fire*, 2024, 7(11): 389.
- [2] Zhao L, Zhi L, Zhao C, et al. Fire-YOLO: 화재 점검을 위한 소형 표적 객체 탐지 방법. *Sustainability*, 2022, 14(9): 4930.
- [3] Wang J, Wang C, Ding W, et al. YOLOv5s-ACE: 개선된 YOLOv5s 기반 산불 객체 탐지 알고리즘. *Fire Technology*, 2024: 1-21.
- [4] Cao X, Wu J, Chen J, et al. 특징 융합과 채널 어텐션에 기반한 복잡 장면 화재 객체 탐지. *Arabian Journal for Science and Engineering*, 2024: 1-15.
- [5] Gragnaniello D, Greco A, Sansone C, et al. 비디오 기반 화재 및 연기 탐지: 새로운 분류 체계에 따른 문헌 고찰. *Expert Systems with Applications*, 2024: 124783.

- [6] G. Jocher and J. Qiu. Ultralytics YOLO11, 2024. [온라인] <https://github.com/ultralytics/ultralytics>
- [7] Ding X, Zhang X, Ma N, et al. RepVGG: VGG 스타일 합성곱 신경망을 다시 위대하게. IEEE/CVF 컴퓨터 비전 및 패턴 인식 학술대회 논문집, 2021: 13733-13742.
- [8] Tong Z, Chen Y, Xu Z, et al. Wise-IoU: 동적 포커싱 메커니즘을 갖는 경계 상자 회귀 손실. arXiv preprint arXiv:2301.10051, 2023.
- [9] de Venâncio P V A B, Lisboa A C, Barbosa A V. 저전력·자원 제약 장치를 위한 심층 합성곱 신경망 기반 자동 화재 탐지 시스템. Neural Computing and Applications, 2022, 34(18): 15349-15368.
- [10] Mamadaliev D, Touko P L M, Kim J H, et al. ESFD-YOLOv8n: 개선된 YOLOv8n 모델 기반 조기 연기 및 화재 탐지 방법. Fire, 2024, 7(9): 303.

번역 주: 모델명, 모듈명, 데이터셋명, 수식 기호 및 정량 수치는 원문 표기를 유지했다. 그림은 번역문에서 캡션과 참조 위치만 표시했으며, 구조도 자체는 원문 PDF를 참조할 수 있다.